

5.12

ابتدا مسئله را بدین حالتیست و با فرض $P = I$ و با نرم l_2 حل می کنیم چون نسبت به داده های
بیرت، کمترین حساسیت است سپس می توان چندکار انجام داد یکی اینکه بدیشنی میای که با داده های
اصلی متفاوت هستند و به عنوان آن میای که جابجا شده اند در نظر بگیریم و جابجا کنیم. یکی اینکه آن میای
که باقی مانده سی ریادی دارند را حذف کنیم و مدل را فیت کنیم بدیشنی در باره انجام دهیم
می توانیم این کارها را - صورت بازگشتی انجام دهیم تا جایی که دیگر داده های بیرت شایانی نمانیم

13.3

$$E u_i^2 \leq 1 \Rightarrow \text{diag}(u u^T) \leq 1$$

$$\Rightarrow \text{diag} [\sigma^2 F(I - GF)^{-1} (I - GF)^T F^T] \leq 1$$

$$E y_i^2 = (y y^T)_{ii} = (\sigma^2 (I - GF)^{-1} (I - GF)^T)_{ii}$$

$$\Rightarrow \min \sigma^2 \max_{i=1, \dots, n} (I - GF)^{-1} (I - GF)^T$$

$$\text{SL: } \text{diag} (F(I - GF)^{-1} (I - GF)^T) \leq \frac{1}{\sigma^2}$$

اما این مسئله Convex نیست. برای حل این مشکل تغییر متغیر برای دهیم.

$$X = F(I - GF)^{-1} \Rightarrow X(I - GF) = F \Rightarrow X = F + XGF \Rightarrow F = (I + XG)^{-1} X$$

$$I = (I - GF)(I - GF)^T = (I - GF)^{-1} - GF(I - GF)^{-1} \quad \text{از طرفی}$$

$$\Rightarrow (I - GF)^{-1} = I + GX$$

$$\min_{i,j=1,\dots,n} \sigma^2 \max_{i,j=1,\dots,n} ((I + GX)(I + GX)^T)_{ii}$$

$$st \quad \text{diag}(\Lambda X^T) \leq \frac{1}{\sigma^2}$$

$$T = \sum_{i=1}^N \frac{d}{S_i}$$

1304

$$\rightarrow \min \sum_{i=1}^N \frac{d}{S_i}$$

$$st: \quad \frac{1}{2} m S_{i+1}^2 + mg h_{i+1} = \frac{1}{2} m S_i^2 + mg h_i + n f_i - d C_D S_i^2$$

$$\sum_{i=1}^N f_i + \frac{PT}{2} \leq F$$

$$f_i \geq 0$$

$$n f_0 = \frac{1}{2} m S_1^2$$

با وجود اینکه فرم مسئله محدب است اما چون در تعدادی مسئله خطی نیست، نمی توان از CVXPY برای حل مسئله استفاده کرد. با تغییر متغیر $Z_i = \sqrt{S_i}$ ، این مشکل برطرف می شود:

$$\min \sum_{i=1}^N \frac{d}{\sqrt{Z_i}}$$

$$st \quad \frac{1}{2} m Z_{i+1} + mg h_{i+1} = \frac{1}{2} m Z_i + mg h_i + n f_i - d C_D Z_i$$

$$\sum f_i + \frac{P}{2} \sum \frac{d}{\sqrt{Z_i}} \leq F$$

$$f_i \geq 0$$

$$n f_0 = \frac{1}{2} m Z_1$$

(a) اگر $x + tv$ انتخاب کنیم، بدون $1^T v = 0$ پس در شرط صدای کند، تابع هدف را برای $t > 0$ زیاد می کند برای

$$\begin{aligned} \min \quad & - \sum p_j \log y_j \\ \text{st} \quad & y = R^T x \\ & 1^T x = 1 \end{aligned} \quad (b)$$

$$\Rightarrow L(x, y, v, \lambda) = - \sum p_j \log y_j + v^T (y - R^T x) + \lambda (1^T x - 1)$$

که اگر $\lambda = 1$ باشد، گرانش از پایین است بعد از کمینه سازی x .

$$\frac{\partial L}{\partial y_j} = - \frac{p_j}{y_j} + v_j = 0 \Rightarrow y_j = \frac{p_j}{v_j}, \quad v_j > 0$$

حال به ازای $\frac{p_j}{v_j} = y_j$ کمینه می شود.

$$L(v, \lambda) = - \sum p_j \log \left(\frac{p_j}{v_j} \right) + 1 - \lambda$$

$$\text{st: } Rv = 1$$

14.10 برای آینه محدب بدون مسند مربع نشود، بتوانیم از $cvxpy$ استفاده کنیم، از متغیرهای S^+ و S^-

$$B_t - E_t + I_t = S_t^+ - S_t^-, \quad S_t^+ \geq 0, \quad S_t^- \geq 0$$

$$B_{t+1} = (1+r_+) S_t^+ - (1+r_-) S_t^-$$

$$\min \quad B_0 + \sum p_i x_i$$

$$\text{st} \quad Ax = I$$

$$x \geq 0, \quad B_0 \geq 0, \quad S_t^+ \geq 0, \quad S_t^- \geq 0$$

$$B_1 = (1+r_+) B_0$$

$$B_T - E_T + I_T = 0$$

$$B_{t+1} = (1+r_+) S_t^+ - (1+r_-) S_t^-, \quad t = 1, \dots, T-1$$

$$B_t - E_t + I_t = S_t^+ - S_t^-$$